

# 대조적 학습을 통한 자가 개선 BeatGAN

황채은

경희대학교 컴퓨터공학과

hce9603@khu.ac.kr

## Self-Improving BeatGAN via Contrastive Learning

Chaeun Hwang

Computer Science and Engineering, Kyung Hee University

### 요약

최근 사람들의 주요 관심사 중에 하나로 건강이 자리매김함에 따라 다양한 질병과 그 진단에 대한 중요도가 높아지고 있다. 그 중에서도 심장 질환은 한국인의 10대 사망 원인 중 하나에 속할 정도로 자주 발생할 수 있는 질병이기에, 이를 진단하고 치료하는 것은 병원에 있어서 중대한 일이 되었다. 현재 병원에서는 환자의 심전도 데이터를 측정하고 기록하여 분석하는 일을 전문 의료 인력에게 의존하고 있으며, 이는 많은 인력과 수고로움을 유발한다. 따라서 본 연구에서는 이러한 문제점을 개선하고자 지식 증류를 도입한 BeatGAN의 모델에 추가적으로 대조적 학습법을 도입하여 개선한 부정맥 예측 딥러닝 모델을 제안한다.

## 1. 서론

### 1.1. 연구배경

최근 기술과 의학이 발전함에 따라, 사람의 수명은 예전보다 많이 늘었다. 사람들은 늘어난 수명만큼 오랜 시간을 건강하게 보내려고 노력하며, 이러한 노력은 당연히 자기 자신과 가족의 건강 문제에 대한 관심으로 직결되고 있다.

최근 들어 많은 사람에게 자주 발생하고, 걱정을 끼치고 있는 질병 중에는 심장 및 혈관 질환이 있다. 심장 질환은 계속 늘어나는 추세이며, 그 중에서도 자주 언급되는 질환 중 하나가 바로 부정맥이다. 부정맥이란, 심장이 불규칙한 리듬이나 비정상적인 심박수를 갖는 것으로, 돌연사나 뇌졸중 등 생과 직결된 중질환을 유발할 수 있다. 통신기술의 발달로 사람들은 텔레비전 매체와 인터넷을 통해 다양하고 폭넓은 건강 지식과 질병에 대해 들을 수 있으며, 이에 따라 늘어나고 있는 부정맥에 대한 관심과 걱정도 커지게 되었다.

본 연구에서는, 정상 심전도 및 부정맥 심전도 그래프를 포함한 다양한 심전도 데이터를 수집, 분석하여 시기반의 딥러닝 알고리즘을 통해 부정맥을 진찰해내는 것을 목표로 한다. BeatGAN은 생성자와 구분자 두 네트워크를 적대적으로 학습시키는 비지도 학습 기반의 생성 모델을 사용하

여 주어진 심전도 데이터에서 비정상적인 beats를 감지한다. BeatGAN은 효율적으로 이상 심전도를 감지해낼 수 있으나, 이러한 생성 모델은 추가적인 training 기법이 존재하지 않았기 때문에 FRSKD(Feature Refinement via Self-Knowledge Distillation : 자기 지식 증류를 통한 특징 개선)을 BeatGAN에 결합하여 보완한 모델에, 새로이 Contrastive Learning 방식을 도입하여 Distillation 부분을 추가로 개선함으로써, 기존의 BeatGAN보다 더 향상된 성능을 낼 수 있는 방법을 연구한다.

## 1.2. 연구목표

비지도 학습 기반의 생성 모델을 이용하여 비정상적인 심전도를 감지할 수 있는 BeatGAN에 자기 지식 증류 FRSKD를 활용한 기존의 모델에 Contrastive Learning 방식을 사용한 SimCLR을 도입하여 기존의 모델보다 더 높은 성능을 보이는 것이 본 연구의 목표이다.

## 2. 관련 연구

### 2.1. BeatGAN

적대적으로 생성된 시계열을 이용하여 비정상적인 리듬을 감지하는 알고리즘이다. (BeatGAN: Anomalous Rhythm Detection using Adversarially Generated Time Series [1]) BeatGAN은 다음과 같은 장점이 있다. 1) 비지도 방식(Unsupervised) : 레이블 없이 적용이 가능하다. 2) 효율성 (Effectiveness) : ECG 데이터에서 거의 0.95 AUC의 정확도를 달성하고 매우 빠른 추론 속도(비트당 2.6ms)를 보인다. 3) 설명 가능성(Explainability): 비정상적인 패턴과 그와 관련된 시간 틱을 정확히 찾아내어 시각화 및 주의 집중을 위한 해석 가능한 출력을 제공한다. 4) 일반성(Generality) : ECG 데이터 뿐만 아니라 다변수 모션 캡처 데이터베이스 (CMU Motion Capture Dataset)에서 비정상적인 움직임을 성공적으로 감지한다.

#### 2.1.1. 이상 탐지 기술 (Anomaly Detection)

의도하지 않은 정상적인 시스템의 동작을 이상 현상이라고 한다. 이상 현상을 해결하기 위해서 발생한 현상이 '이상 상태'임을 인지해야 한다. 이상 현상이 정상의 양상과 많이 달라 쉽게 인지할 수 있을 때가 있지만, 정상과 굉장히 유사해서 인지하기 어려울 때도 있다. 이는 다양한 분야에서 발생할 수 있으며 이를 탐지하기 위해 '이상 탐지 기술' 연구가 진행되고 있다. 학습 시 비정상 샘플과 라벨의 유무에 따른 분류로 지도(Supervised) 이상 탐지와 비지도(Unsupervised) 이상 탐지가 있다. BeatGAN의 경우 비지도 이상 탐지 기술로 라벨링의 과정이 필요가 없는 장점이 있지만 다른 방법 대비 정확도가 낮은 단점이 있다.

### 2.1.2. 재구성 기반 판별 방식 (Reconstruction)

이상 판별할 데이터를 저차원 형태의 잠재 구조(latent structure)를 획득하고 인위적으로 재구성한 데이터를 생성하기 위한 모델을 사용한다. 대표적인 방법으로 PCA(Principal Component Analysis, 주성분 분석)이 있다. 주어진 데이터에 대해 PCA를 이용하면 데이터의 차원을 축소하고 복원하는 과정을 통해 비정상 샘플을 검출한다. 단점으로는 선형 재구성으로만 제한이 된다. 딥러닝 기반 기술에서는 주로 오토인코더(Autoencoder)기반의 방법론이 자주 사용된다. AE(Auto-Encoder), VAE(Variational Auto-Encoder), LSTM 기반 인코더-디코더 구조가 있으며, PCA와 달리 비선형 차원 축소를 다룰 수 있다.

### 2.1.3. GAN (Generative Adversarial Networks)

생성자(Generator)와 구분자(Discriminator) 두 네트워크를 적대적(Adversarial)으로 학습시키는 비지도 학습 기반의 생성모델(Unsupervised generative model)이다. GAN은 생성자가 만든 가짜 데이터가 진짜 데이터와 비슷하여 판별자가 진위를 판별하지 못할 때까지 알고리즘을 개선하는 방식으로 학습을 진행한다. 이처럼 GAN으로 학습하는 생성자는 진짜 같은 가짜 데이터를 만들어 내기 때문에, 유명 화가의 화풍을 입힌 이미지나 음성 변조 파일, 영상 등 다양한 콘텐츠 분야에서 활용되고 있다.

## 2.2. Feature Refinement via Self-Knowledge Distillation

### 2.2.1. 지식 증류 (Knowledge Distillation)

딥러닝에서 지식 증류는 큰 모델(Teacher Network)로부터 증류한 지식을 작은 모델(Student Network)로 전달하는 과정이다. 복잡한 모델은 실제 서비스로 배포할 때 사용자들에게 적합하지 않을 수 있다. 만약 작은 모델이 더 큰 모델만큼의 성능이 나온다면 배포 시 적합하며 컴퓨팅 자원 측면에서도 효율적일 것이다. 지식 증류는 학습 과정에서 큰 네트워크로부터 증류된 지식이 작은 네트워크로 전달하고 그의 성능을 높이는 것에 목적이 있다.

모델이 이미지 클래스를 분류할 때 각 클래스의 확률값이 출력된다. 가장 높은 확률을 보이는 클래스에 따라 예측을 하는 구조로, 교사 네트워크의 분류 결과를 학생 네트워크의 분류 결과와 비교시켜서 학생이 교사를 모방하도록 학습시킨다. 여기에서 예측한 클래스 이외의 확률값에 주목하여 학생 모델이 이러한 정보의 손실 없이 학습할 수 있도록 기존 softmax 함수에 하이퍼파라미터  $T$ (Temperature)를 반영한다. 이를 사용하면 낮은 입력 값의 출력을 크게 만들어주고, 큰 입력 값의 출력은 작게 만들어 전체적으로 출력 값을 부드럽게 만들어준다. 이러한 방법으로 지식 증류는 교사와 학생 두 네트워크의 분류 결과를 hard label이 아닌 소프트 레이블(soft label)로 사용하여 학생 네트워크가 학생 네트워크를 모방하여 학습할 때의 이점을 최대화하고 성능을 높인다.

### 2.2.2. 자가 지식 증류 (Self-Knowledge Distillation)

사전에 학습된 교사 네트워크의 출력 값에 softmax 처리한 값을 활용하여 학생 네트워크를 학습시키는 기존의 지식 증류 방법과 달리, 자가 지식 증류는 단일 모델 내부에서 지식을 증류하는 방법이다. 자가 지식 증류는 데이터 증강 기반 방식과 보조 네트워크 기반 방식으로 크게 두가지가 있다. 데이터 증강 기반 방식은 딥러닝 모델을 학습시키는 데 필요한 데이터를 확보하는 기법 중 하나로, 소량의 학습 데이터에 인위적인 변화를 가하여 새로운 학습 데이터를 확보하는 방법이다. 단점으로 데이터의 증강 과정에서 지역 정보(local information)를 잃어 지식 증류의 성능을 향상시킬 수 있는 기술인 특징 증류(feature distillation)를 활용하기 어렵다. 보조 네트워크 기반 방식은 분류기 네트워크 중간에 추가 경로를 활용하고 지식 전달을 통해 추가 분기를 유도하여 유사한 출력을 생성한다. 하지만 이 방식은 특징을 더욱 복잡하게 만들 수 없는 단점이 있다.

### 2.2.3. FRSKD (Feature Refinement via Self-Knowledge Distillation)

기존의 자가 지식 증류 방법의 단점을 보완하여 개선한 방법이 FRSKD이다. FRSKD는 자가 지식 증류를 위해 특징 증류를 활용할 수 있고 소프트 레이블로 정제된 지식을 생성하여 사용이 가능하다. 따라서 지역 정보의 보존을 강조하는 분류 및 의미 분할에 적용이 될 수 있으며 다른 자가 지식 증류 방법과도 호환이 되는 장점이 있다. BiFPN의 구조를 수정하여 하향식과 상향식 경로를 적용한 자가교사 네트워크를 모델링한다. 특징 증류(feature distillation)는 주의 전달(attention transfer)을 적용했으며 이를 통해 분류기 네트워크가 자가 교사 네트워크에서 정제된 기능맵의 위치를 학습하도록 유도한다. 최적화 목표는 Cross Entropy 손실함수( $L_{CE}$ )와 특징 증류의 손실함수( $L_f$ ), 분류기 네트워크와 자가 교사 네트워크 각 출력 값에 대한 손실함수( $L_{KD}$ ) 총 세가지를 통합하여  $L_{FRSKD}$ 로 구성한다.

## 2.3. Contrastive Learning

Contrastive Learning은 Unsupervised Learning 방식의 학습 알고리즘으로, 여기서 Unsupervised Learning은 데이터의 label없이 네트워크 모델을 학습하는 것을 의미한다. Contrastive Learning은 각 항목의 차이를 학습하는 방식으로, Positive pair와 Negative pair로 구성된다. 여기서 각 pair에 대해 Positive pair는 같게, Negative pair는 다르게 구분하면서 모델을 학습하는 방식이다. 이러한 방식은 기존에 발표된 여러 CPC나 CMC등의 연구들보다 뛰어난 성능을 보여준다.

### 2.3.1. SimCLR

SimCLR은 Unsupervised Learning인 Contrastive Learning 방식을 사용하는 학습 모델이다. 이 모델은 각 이미지에서 서로 다른 두 Data augmentation을 적용하여, 같은 이미지로부터 나온 결

과들은 Positive pair로 정의하고, 서로 다른 이미지로부터 나온 결과들은 Negative pair로 정의하는 형태로 Contrastive Learning 방식을 적용하였다. 이 각 Pair들은 CNN기반의 네트워크(Base Encoder)를 통과하여 visual representation embedding vector로 변환된다. 이 벡터들은 다시 MLP기반의 네트워크(Projection Head)를 통과하여 변환되고, 변환된 결과들을 이용하여 Contrastive Loss를 계산할 수 있다.

Encoder와 Projection head는 둘 다 batch 단위로 학습을 하며, batch size가 N일 경우 2N개의 sample이 data augmentation을 통해 생성된다. 이러한 방식으로 각 sample별로 1쌍의 Positive pair와 2(N-1)쌍의 Negative pair가 구성된다. SimCLR은 Positive pair간의 유사성은 높이고, Negative pair간의 유사성은 최소화하는 형태로 Loss Function을 구성한다.

일반적으로 Contrastive Learning 방식으로 학습을 할 때, 질이 좋고 충분히 많은 양의 Negative pair를 필요로 하기 때문에 큰 batch size가 필요하다. 따라서 SimCLR은 기본적으로 4096의 batch size(총 8192개의 sample)를 이용하여 학습하며, 128 코어의 cloud TPU를 사용한다. 또한 SimCLR은 큰 크기의 batch size 학습에 용이한 LARS optimizer를 이용하여 분산학습으로 학습하고, Batch normalization을 적용할 때 모든 device에서의 평균/표준편차 값들을 통합하여 적용함으로써, Batch normalization 과정에서 발생하는 정보 손실을 최소화한다.

### 3. 프로젝트 내용

#### 3.1. 시나리오

BeatGAN은 대규모의 리듬 시계열 데이터, 즉 ECG(심전도) 데이터에서 효과적이고 효율적인 방법으로 비정상적인 심전도를 감지해낼 수 있는 알고리즘이며, FRSKD는 지식 증류 방법 중 기존의 자가 지식 증류 방법의 단점을 보완한 방법으로 보조 자가 네트워크 교사를 활용하여 분류기 네트워크에 정제된 지식을 전달함으로써 데이터 증강 및 모델의 학습에 효과적인 알고리즘이다. 또한 SimCLR은 data augmentation을 통해 얻은 Positive/Negative Sample 들에 대해 Contrastive Learning을 적용시켜 학습하는 모델로, Supervised Learning을 통해 학습한 모델들에 준하는 성능을 보여주는 Unsupervised Learning 기반의 학습 모델이다.

BeatGAN은 적대적 생성 접근 방식을 사용한 재구성 오류의 정규화와 시계열 워핑을 사용한 데이터 보강으로 견고성이 보장되어있고, 직관적인 접근 방식을 제공하지만 데이터를 증강시키는 것은 따로 언급되어 있지 않다. 기존의 연구에서는 이러한 BeatGAN에 FRSKD를 접목함으로써 이러한 단점을 보완했었으나, 눈에 띄는 성능의 향상은 가져오지 못했다. 따라서 본 연구에서는 BeatGAN의 알고리즘에 FRSKD의 자가 지식 증류 방법을 접목한 기존의 모델에, Contrastive Learning 방식을 사용한 SimCLR 모델을 도입하여 지식 증류의 성능을 향상시킴으로써 BeatGAN에 제공되는 데이터를 효과적으로 증강시키는 것을 목적으로 한다. BeatGAN의 기존 데이터를

FRSKD와 SimCLR을 통해 데이터를 증강 및 학습하고, 이렇게 정제된 데이터를 다시 BeatGAN의 데이터에 보강함으로써 결과적으로 BeatGAN의 성능을 향상시키고 더 높은 AUC를 끌어낼 수 있도록 한다.

BeatGAN과 FRSKD 및 SimCLR은 모두 성능이 보장되어 있는 알고리즘이며 공개된 코드로 배포되고 있으므로, 이 공개된 코드들을 취합하여 효율적인 알고리즘을 도출한다.

## 3.2. 요구사항

BeatGAN은 ECG 데이터에서 비정상적인 샘플을 감지할 때 우수한 성능을 보여준다. 비정상적인 패턴과 그와 관련된 시간 틱을 정확히 찾아내며 거의 0.95 AUC의 정확도를 달성하고 매우 빠른 추론 속도(비트당 2.6ms)를 보여준다. 기존의 연구를 통해 BeatGAN에 FRSKD를 도입하여 AUC를 다소 향상시킬 수 있었으나, 본 연구에서는 이에 더하여 Contrastive Learning 방식을 도입한 SimCLR을 추가로 도입함으로써 보다 높은 정확도를 보여줄 수 있도록 개선한다.

## 3.3. 시스템 설계

### 3.3.1. BeatGAN 네트워크 구조




Figure 1. 기존 BeatGAN 네트워크의 구조

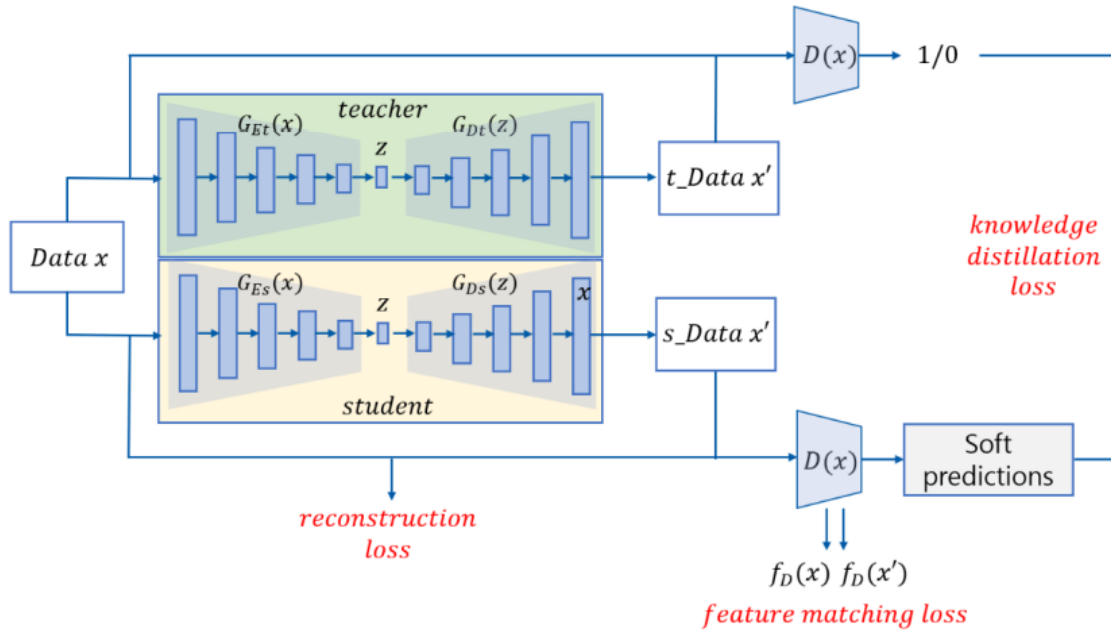


Figure 2. Knowledge Distillation을 적용한 SI-BeatGAN의 네트워크 구조

### 3. 3. 2. 연구 진행

#### 3. 3. 2. 1. SimCLR의 구조와 기능

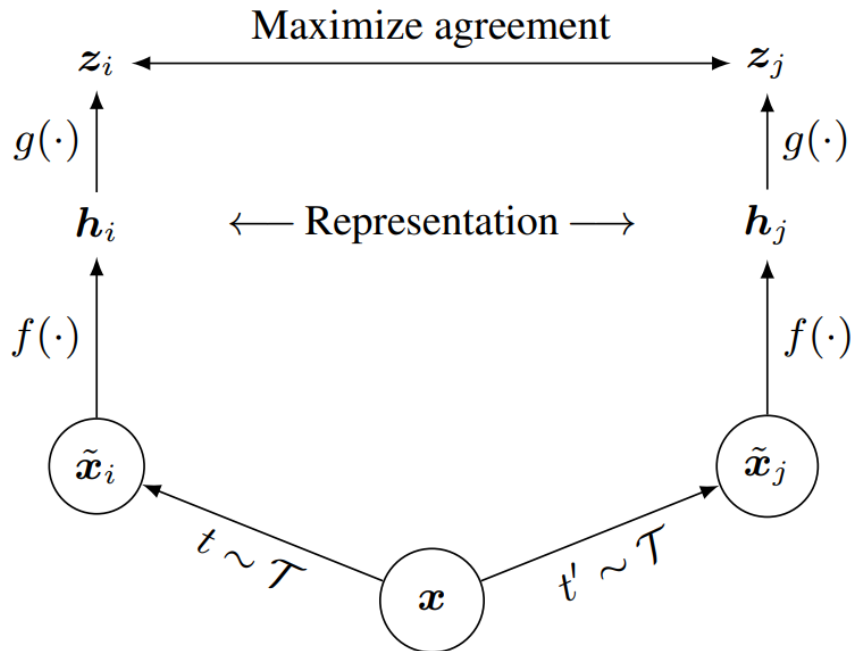


Figure 3. SimCLR의 구조

SimCLR은 각 이미지에 서로 다른 두 개의 Data augmentation을 적용하여, 같은 이미지로부터 나온 결과는 Positive pair로 정의하고, 서로 다른 이미지로부터 나온 결과들은 Negative pair로 정의하는 형태로 Contrastive Learning 방식을 적용한 모델이다.

Figure 3은 SimCLR의 구조를 그림으로 나타낸 것이다. 하나의 이미지( $x$ )에서 Data augmentation을 거쳐 생성된 두 개의 이미지( $x_i, x_j$ )로 나뉘어지고, 이렇게 변환된 이미지는 Positive pair로 정의한다. 이렇게 변환된 이미지( $x_i, x_j$ )들은 CNN기반의 네트워크( $f$ )를 통과하여 Visual representation embedding vector( $h_i, h_j$ )로 변환된다. 이 때 사용되는 네트워크를 base encoder라고 부르며, SimCLR에서는 ResNET을 이용한다. 이렇게 생성된 Visual representation vector는 Projection head라고 불리는 MLP 기반의 네트워크( $g$ )를 통과하여 변환되고, 변환된 결과( $z_i, z_j$ )를 이용하여 Contrastive loss를 계산한다.

SimCLR에서 positive pair( $i, j$ )에 대한 Contrastive loss는 다음의 식과 같다.

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}$$

### 3. 3. 2. 2. 손실함수

기존의 프로젝트에서 진행했던 SI-BeatGAN의 손실함수는 다음과 같다.

$$L_G = \|x - x'\|_2 + \lambda \|f_D(x) - f_D(x')\|_2$$

$$L_{KD}(x; \theta_s, \theta_t, T) = D_{KL}(\text{softmax}(\frac{f_s(x; \theta_s)}{T}) \| \text{softmax}(\frac{f_t(x; \theta_t)}{T}))$$

$$L = L_G + L_{KD}(x; \theta_s, \theta_t, T)$$

SimCLR의 손실함수는 아래와 같으며, 이는 Contrastive Learning을 적용한 손실함수이다.

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}$$

## 4. 프로젝트 결과

### 4.1. 개발 환경

프로젝트 진행은 로컬 컴퓨터로 진행하려 했으나, 현재 로컬 환경의 부족으로 실행되지 않는 것들이 많아 다양한 시도를 하였으나 대부분 실패로 돌아갔다. 따라서 본 연구는 로컬 환경에서 코드를 실행하는 것 대신 이론적 개선 방안을 제시하는 데에 중점을 두었다.

현재 로컬 환경은 다음과 같다.

- OS : Windows 10
- VGA : Intel(R) HD Graphics 520
- VGA Driver : 21.20.16.4565
- Python version : 3.10. (코드 버전 : 3. 7. 12.)



## 4.2. 연구 데이터

본 연구에 사용할 데이터는 MIT-BIH arrhythmia database를 이용한다. 이 데이터는 일반적으로 부정맥 감지를 평가하는 데 사용할 수 있는 데이터로, 심전도와 관련 있는 딥러닝 분야에서 많이 사용되고 있으므로 좀 더 신뢰도 있는 결과를 이끌어낼 수 있을 것이다. 이 데이터는 피험자 47 명으로부터 수집한 2채널 구성의 24시간 ECG 기록을 30분동안 발췌한 총 48개로 구성되어 있으며, 본 프로젝트의 연구에서는 기존 BeatGAN의 연구에 이용하던 데이터를 그대로 사용하였다. 이 데이터에는 총 97,568개의 비트와 2,860만의 시간 틱이 포함되어 있다.

## 4.3. 연구 결과

이번 프로젝트에 따른 연구 결과로 기존에 제시되었던 SI-BeatGAN의 개선에 대해서 아래와 같은 두 가지 시나리오를 도출해낼 수 있었다.

### 4. 3. 1. 시나리오 1 – SimCLR의 적용

SimCLR은 Contrastive Learning이 적용된, 데이터의 label없이 네트워크 모델을 학습할 수 있는 Unsupervised Learning 모델로서, 뛰어난 성능을 보이는 모델이다. SimCLR은 Positive pair와 Negative pair를 생성하여 네트워크를 통과시킴으로써 이들을 변환시키고, 변환된 결과를 활용하여 Contrastive Loss를 계산한다.

SimCLR은 여러 번의 연구와 논문을 거쳐 현재 Ver.2까지 발전하였고, 이는 GitHub를 통해 공개적으로 배포되고 있으므로, 활용이 무궁무진하다.

이미 공개적으로 코드가 배포되고 있고, 성능 또한 여러 번의 논문을 통해서 검증된 바 있는 SimCLR을 활용하면, 기존의 SI-BeatGAN의 성능을 향상시킬 수 있을 것이라고 생각한다.

SimCLR은 Contrastive Learning 기법을 활용하여 서로 일치하는 것끼리는 더 가까이 모으고, 서로 다른 것끼리는 더 멀리하게 함으로써 기능하는데, 이를 BeatGAN의 Discriminator에 적용한다면 BeatGAN에서 정상 심전도에서 이상 심전도를 구분해내는 성능이 높아져 AUC를 높일 수 있을 것으로 기대할 수 있다.

따라서, SimCLR의 공개된 코드에서 Contrastive Learning을 수행하는 모델 부분을 기존의 SI-BeatGAN의 Discriminator 부분에 적용하여 결합시킴으로써 모델 성능의 개선을 꾀할 수 있다.

### 4. 3. 2. 시나리오 2 – Contrastive Learning의 손실함수 적용

모델의 성능은 손실함수(Loss Function)를 개선하는 것만으로도 유의미하게 올릴 수 있음을 이전 프로젝트를 통해 알 수 있었고, 따라서 이번에도 손실함수를 수정하여 개선함으로써 모델의 성능을 향상시켜 더 높은 AUC를 얻을 수 있을 것이다.

기존의 BeatGAN에서 사용했던 손실함수는 아래와 같다.

$$L_G = ||x - x'||_2 + \lambda ||f_D(x) - f_D(x')||_2$$

$$L_{KD}(x; \theta_s, \theta_t, T) = D_{KL}(\text{softmax}(\frac{f_s(x; \theta_s)}{T}) || \text{softmax}(\frac{f_t(x; \theta_t)}{T}))$$

$$L = L_G + L_{KD}(x; \theta_s, \theta_t, T)$$

그리고 Contrastive Learning을 적용한 SimCLR에서 제시한 손실함수는 아래와 같다.

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{I}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}$$

따라서, 이 손실함수들을 적절히 통합하여 모델에 적용할 수 있다면, BeatGAN의 성능은 향상될 것이다. 기존의 SI-BeatGAN은 Contrastive Learning 방식을 적용하고 있지 않은 상태이기 때문에, 이 손실함수의 통합을 통해 Contrastive Learning의 방식도 적용하게 된다면, 주어진 ECG 데이터에서 이상 심전도 데이터를 찾아내는 데에서 더 높은 정확도를 보일 수 있을 것이다.

## 5. 결론

### 5.1. 기대 효과

이전의 프로젝트에서 BeatGAN에 지식 증류를 활용하여 개선한 SI-BeatGAN과, 이번 프로젝트에서 연구한 SimCLR은 모두 논문을 통해 연구 결과가 검증되어 있고, GitHub에 코드가 공개적으로 배포되고 있는 모델이다. 따라서 이 모델들은 앞으로도 더 많은 연구와 접목시켜 더 나은 개선방향을 찾을 수 있으며, 기존의 코드에서 다른 모델의 코드를 접목시키거나 활용하기 용이할 것이다. 본 프로젝트의 1차 목표는 Contrastive Learning의 방법을 활용한 SimCLR 모델을 활용함으로써 SI-BeatGAN의 성능을 증진시키는 데에 있다. 본 연구를 통해 개선될 SI-BeatGAN은 Contrastive Learning을 통해 학습을 함으로써 주어진 ECG 데이터에서 예상하기 어려운 비정상적인 심전도에서도 부정맥 여부를 좀 더 정확하게 판별할 수 있을 것이다. 즉 본 연구를 통해, SI-BeatGAN의 성능을 향상시키기, 즉 SI-BeatGAN의 AUC를 높이는 일을 할 수 있으리라 기대할 수 있다.

### 5.2. 추후 연구 방향

본 프로젝트에서는 SI-BeatGAN의 일부분만을 수정하여 개선하는 방안을 내놓았고, 이는 유의미한 AUC의 향상으로 이어질 수 있다. 하지만 본 프로젝트에서는 로컬 환경의 부재로 인해 실제로 코드에 개선을 적용하지 못했고, 전체적인 개선 및 유의미한 향상을 이끌어내지는 못했다. 따라서, 향후에는 프로젝트의 모델에서 실제로 코드를 접목시켜 봄으로써 예상했던 성능 향상을 확인할 수 있고, 좀 더 나아가 전체적인 코드의 개선이 가능할 것으로 예상된다. 최근, 딥러닝 모델의 연구가 활발해짐에 따라 뛰어난 성능을 보이는 Contrastive Learning에 대해서도 꾸준한 연구가 이

어질 것이고, 이를 활용한 새로운 형태의 모델 또한 등장하게 될 것이다. 이렇게 새로 등장한 발전된 모델들을 연구하고 본 프로젝트에 추가적으로 도입해봄으로써, 더 나은 방향의 개선을 추구할 수 있을 것이다.

이러한 방식으로 프로젝트에 제시된 모델을 추가적으로 개선해나가고 AUC를 더 향상시킴으로써 계속해서 발전해나간다면, 실제 의료 환경에서 본 모델을 활용해 환자의 ECG 데이터를 수집하고 분석하고 판별함으로써 환자의 이상 심전도를 더욱 빠르고 정확하게 감지해낼 수 있을 것이다. 이를 통해 부정맥 등의 이상 질환을 손쉽게 잡아내고 빠른 치료로 이어질 수 있고, 이는 의료 서비스의 발전에 기여하게 될 것으로 기대할 수 있다.

## 6. 참고문헌

- [1] Zhou B, Liu S, Hooi B, Cheng X, Ye J. BeatGAN: Anomalous Rhythm Detection using Adversarially Generated Time Series, Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence Main track. Pages 4433-4439, 2019
- [2] Ji M, Shin S, Hwang S, Park G, Moon I. Refine Myself by Teaching Myself : Feature Refinement via Self-Knowledge Distillation. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 10664-10673, 2021
- [3] 임에딘, 황채은. (2021). 지식 증류를 통한 자가 개선 BeatGAN(Self-Improving BeatGAN via Knowledge Distillation). 경희대학교 컴퓨터공학과 학부생논문.
- [4] Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020, November). A simple framework for contrastive learning of visual representations. In International conference on machine learning (pp. 1597-1607). PMLR.
- [5] Alec Radford, Luke Metz, Soumith Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. arXiv preprint arXiv:1511.06434, 2015
- [6] George B Moody and Roger G Mark. The impact of the mit-bih arrhythmia database. IEEE Engineering in Medicine and Biology Magazine, 20(3):45–50, 2001